

# 自然言語処理によるテキスト分析

中央大学理工学部ビジネスデータサイエンス学科

23D7104001I 高木悠人

---

## 1. SNS を用いた商品の評判分析

### 1.1. 実験の背景と目的

近年、あらゆる商品、サービスの購買行動が活発化する中で、口コミを一つの判断基準とする人が多い。特に、Amazon では口コミが妥当かを評価する「さくらチェッカー」というサービスが登場し、信頼できる口コミへの需要の高さが伺える。本実験では、SNS 上で投稿された商品に関する口コミに対し、感情分析を行い可視化することを目的とする。また、商品の特徴についても評価(アスペクトベースセンチメント分析)を行い、どのような特徴が商品全体に大きく影響しているのかを分析する。

### 1.2. 商品のレビュー文の分析

商品のレビュー文に対してセンチメント分析を行う方法について、以下に示す。

- (1) 投稿文が格納されているテキスト形式のファイルをダウンロードし、Google Colab 上で読み込む。
- (2) 投稿文がレビュー文であるかを Chat GPT(API 形式)に評価してもらうため、適切なプロンプトを考える。
- (3) (2)のプロンプトを元に、レビュー文を抽出する。
- (4) 抽出したレビュー文をテキストファイルに格納する。
- (5) アスペクトベースセンチメント分析を行うための適切なプロンプトを考える。
- (6) (5)のプロンプトをもとに Chat GPT(API 形式)でのアスペクトベースセンチメント分析を行う。
- (7) 分析結果を図示することで、可視化する。

### 1.3.実験

#### 1.3.1. 実験データ

まず、実験データを示す。今回は、投稿文が実験データとなるためそれぞれの商品に対する投稿の収集期間と投稿数を表 1 に示す。今回の実験では、以下のスマートウォッチ(Apple Watch, Fitbit)とスマートフォン(Galaxy, Google Pixel, iPhone)について、調査する。

表 1. 実験データ

製品	Apple Watch	Fitbit	Galaxy	Google Pixel	iPhone
収集開始	2022/9/1	2022/9/1	2022/9/1	2022/10/1	2022/9/1
収集終了	2022/9/30	2022/10/31	2022/9/30	2022/10/31	2022/9/30
Tweet数	11009	1561	8859	35922	165120

#### 1.3.2. 評価方法

本実験では、収集した Tweet から、レビュー文ではないものを除外し、残ったものを分析するようにした。除外については、ChatGPT を利用し、以下のプロンプトを利用した。

“次の文が「製品やサービスに対するレビューに関するツイート」であれば、その文をそのまま出力してください。もしレビューに関する内容でなければ、空文字列"を出力してください。【入力文】 {s} 【出力】 ”

このレスポンスに対して、if 文で条件分岐し、空文字列でない場合は、分析対象とした。ただし、表 1 のように膨大な量の分析を行うと、API 利用料金がかさむため本実験では 100 文に絞って解析した。

次に、抽出文についてアスペクトベースセンチメント分析を実施した。以下にアスペクト一覧を示す。

- スマートウォッチ
  - バッテリー
  - 操作性
  - デザイン
  - 機能性
  - サイズ・装着感

- スマートフォン
  - レスポンス
  - カメラ
  - 操作性
  - バッテリー
  - デザイン
  - 画面表示

上記のアスペクトに対して、センチメント分析をするため、ChatGPT へのプロンプトを以下のように定義した。

“ 以下の"入力"の文をアスペクトベースセンチメント分析を以下の"3つのルール"に従って実行してください。

"ルール 1"

対象が"スマートウォッチ"であれば、[バッテリー,操作性, デザイン,機能性, サイズ・装着感]5種類の観点それぞれでアスペクトベースセンチメント分析を実行してください。

対象が"スマートフォン"であれば、[レスポンス,カメラ,操作性,バッテリー,デザイン,画面表示]6種類の観点それぞれでアスペクトベースセンチメント分析を実行してください。

"ルール 2"

センチメントは、[ポジティブ, ネガティブ, ニュートラル]のどれかとしてください。

"ルール 3"

出力形式は、csv としてください。

"入力"

""+s”

上記のプロンプトを用いて分析を進めた。

#### 1.4.結果

まず、レビュー文抽出した結果、63 の投稿がレビュー文と評価されたとわかった。それらをもとに、アスペクトベースセンチメント分析を実施した結果、以下のとおりとなった。




図 1. Apple Watch のアスペクトベースセンチメント分析結果




図 2. Fitbit のアスペクトベースセンチメント分析結果




図 3. Galaxy のアスペクトベースセンチメント分析結果




図 4. Google Pixel のアスペクトベースセンチメント分析結果




図 5.iPhone のアスペクトベースセンチメント分析結果

### 1.5.考察

本分析では、各製品に対するユーザーのレビュー文を ChatGPT でアスペクトベースセンチメント分析した。その結果、全体的に「バッテリー」は最も多く求められていることがわかり、Fitbit や Apple Watch ではポジティブ意見が顕著だった。一方で、iPhone や Pixel ではバッテリーに対するネガティブ意見も目立ったため、スマートフォンを長時間使うユーザが多いためであると考えた。一方、「デザイン」は iPhone と Pixel で高評価を受けており、ブランド価値が表れている。「カメラ」はスマートフォン特有の重要アスペクトで、iPhone が圧倒的にポジティブ評価を獲得している。「サイズ・装着感」はスマートウォッチで特に重視され、Fitbit で高評価が多い。「操作性」や「機能性」については全体的に意見が少ないが、iPhone と Apple Watch で比較的评价されていた。製品ごとに評価のポイントが異なり、それぞれの強みや課題が明確に現れた分析結果となった。

### 1.6.結論

本分析から、製品ごとにユーザーが重視するアスペクトが異なることが明らかとなった。スマートウォッチでは「バッテリー」と「装着感」が特に重視されており、スマートフォンでは「カメラ」と「デザイン」が評価されやすい。iPhone はデザイン・機能性に強みがある一方、バッテリーに課題が見られた。Pixel は全体的にバランスが良く、Fitbit は快適性に優れていることがわかった。今後の商品開発や

訴求戦略において、セグメント調査としての有用性を知ることができた。また、ChatGPT による感情分析がどの程度精確なのか、別の感情分析モデルを利用した比較を行うことを、今後の展望とする。

## 2. 金融テキストを用いた企業の業績予測

### 2.1. 実験の背景と目的

近年、金融取引における AI の利用は活発化している。特に株の取引などでは、ボッターという取引を自動化する仕組みや、機械学習を利用した予測なども行われている。その中で、企業の事業に関する情報を機械学習が読みやすい形式に変換し、事業動向を予測することは、非常に重要であるといえる。本実験では、企業の事業に関する文書として、有価証券報告書を参照し、ChatGPT を使って抽出、線形回帰モデルでの予測を行う。そして、ChatGPT のデータ整形時での有用性や線形回帰モデルでの予測精度を把握することを本実験の目的とする。

### 2.2. 有価証券報告書を用いた企業の業績予測

有価証券報告書(.xbrl 形式)から、表データの抽出、整形を ChatGPT で行い、次年度の売上予測を線形回帰モデルで分析する。

### 2.3. 実験

#### 2.3.1. 実験データ

本実験では、SUBARU を調査対象とした。SUBARU は、有名な日本の自動車メーカーであり電気自動車や AI による自動運転などにおける安全性能の研究が活発化する中で、どの程度開発費等にコストを割いているのか気になったため、調査することとした。

#### 2.3.2. 評価方法

本実験では、以下のプロンプトを用いて ChatGPT で売上高、セグメント利益、負債、セグメントの説明等を抽出する。それをもとに、線形回帰モデルで事業動向を分析する。その中で、モデルの学習対象は、2015 年から 2024 年分で 2025 年(決算年)を予測対象とした。それにより、予測した数値と実際の値の比の値を本実験での評価とする。

# prompt

```
messages=[  
    {"role": "system", "content": "あなたは金融のエキスパートです。"},  
    {"role": "user", "content": ""}
```

以下の文章から、セグメントの名称、開発費、売上高、セグメント利益、負債を抽出し、tsv 形式のひとつの表にまとめよ。ただし、文章に記載されていない情報は-にしておくこと。tsv 以外のデータは出力しないこと。

```
""+prompt_table},  
    ],
```

## 2.4.結果

分析に利用した、2015 年から 2025 年のデータを以下に示す。

表 2. 2015 年の分析対象データ

セグメントの名称	開発費	売上高	セグメント利益	負債
自動車	98,470	2,698,974	400,874	-
航空宇宙	4,172	142,801	18,912	-
産業機器	859	29,029	779	-
その他	7,154	7,109	1,884	-

表 3. 2016 年の分析対象データ

セグメントの名称	開発費	売上高	セグメント利益	負債
自動車	128,254	3,044,176	543,609	-
航空宇宙	6,166	152,786	18,201	-
産業機器	591	32,755	82	-
その他	648	7,478	2,894	-

表 4. 2017 年の分析対象データ

セグメントの名称	開発費	売上高	セグメント利益	負債
自動車	143,227	3,151,961	397,657	-
航空宇宙	13,891	138,759	9,102	-
その他	1379	35,272	3512	-

表 5. 2018 年の分析対象データ

セグメントの名称	開発費	売上高	セグメント利益	負債
自動車	133,388	3,234,866	361,454	-
航空宇宙	7,640	142,163	12,259	-
その他	325	28,192	5066	-



表 6. 2019 年の分析対象データ

セグメントの名称	開発費	売上高	セグメント利益	負債
自動車	106,366	3,014,476	184,947	-
航空宇宙	5,525	131,669	6,047	-
その他	1588	14,369	3846	-

表 7. 2020 年の分析対象データ

セグメントの名称	開発費	売上高	セグメント利益	負債
自動車	119,307	3,193,949	200,263	-
航空宇宙	4,293	142,141	5,065	-
その他	2402	8,019	3577	-

表 8. 2021 年の分析対象データ

セグメントの名称	開発費	売上高	セグメント利益	負債
自動車	80,231	2,737,503	109,067	-
航空宇宙	5,438	87,693	△9,811	-
その他	524	5,014	3070	-

表 9. 2022 年の分析対象データ

セグメントの名称	開発費	売上高	セグメント利益	負債
自動車	-	2,677,465	92,541	-
航空宇宙	-	62,291	-7,005	-
その他	-	4,764	4782	-

表 10. 2023 年の分析対象データ

セグメントの名称	開発費	売上高	セグメント利益	負債
自動車	118,539	3,690,551	263,261	-
航空宇宙	3,636	79,019	△2,082	-
その他	665	4,898	6261	-

表 11. 2024 年の分析対象データ

セグメントの名称	開発費	売上高	セグメント利益	負債
自動車	159,452	4,593,639	461,524	-
航空宇宙	6,087	104,317	2,667	-
その他	1956	4,991	3633	-

次に、予測対象となる 2025 年のデータを以下に示す。

表 12. 2025 年の分析対象データ

セグメントの名称	開発費	売上高	セグメント利益	負債
自動車	166,435	4,569,035	420,410	-
航空宇宙	9,177	111,584	△19,642	-
その他	532	5,144	3687	-

上記のデータを文字列として、以下のプロンプトで ChatGPT に評価させた。

```
#prompt
messages=[
    {"role": "system", "content": "あなたは金融のエキスパートです。"},
    {"role": "user", "content": ""}
以下は、過去数年間のセグメント事業、開発費、売上高、セグメント利益、負債を
まとめたものである。これらのデータのうち売上高の傾向についてわかることをま
とめよ。なお、金額の単位が億円、円、100万円など混在しているので注意する
こと。
"+prompt_gpt},
    ],
```

上記のプロンプトを元に、分析した結果以下の回答が得られた。

```
#response-----
過去数年間のデータを分析すると、各セグメントの売上高について以下の傾向が見
られます。

### 自動車セグメント：
- **2015 年から 2016 年**にかけて、売上高は約 2,699 千億円から約 3,044 千億円
へ増加しました。
- **それ以降 2020 年まで**は多少の変動を見せたものの、概ね 3,000 千億円台を
維持し続けました。
- **2021 年から 2022 年**には、一時的に 2,677 千億円にまで減少しましたが、
- **2023 年に再び反発**し、約 3,691 千億円、さらに**2024 年には 4,594 千億円**
に達し、大幅に増加しています。
```

### 航空宇宙セグメント：

- \*\*2015 年から 2016 年\*\*に売上高が約 143 千億円から約 153 千億円に増えた後、
- \*\*2017 年以降\*\*一貫して減少傾向にあります。特に\*\*2021 年と 2022 年\*\*には大幅に減少し、87 千億円、62 千億円にまで下落しました。
- \*\*2023 年と 2024 年\*\*にはわずかな回復が見られ、104 千億円に戻しましたが、過去の最高額には届いていません。

### その他セグメント：

- このセグメントは全体の売上高の中で割合が小さく、売上高は一貫して 5 千億円以下で推移しています。
- \*\*2023 年と 2024 年\*\*には売上が横ばい状態にあり、主要な変動は観察できません。

### 総合的な売上高の傾向：

- 自動車セグメントが大きな影響力を持ち、2023 年と 2024 年には特に自動車セグメントの成長が全体の売上高増加を牽引しています。
- 航空宇宙セグメントは長期的に見て課題が多く、売上の回復には新たな基盤の整備が必要だと考えられます。
- その他セグメントは小規模かつ安定的な傾向があるため、今後も大幅な変動は見込みにくいでしょう。

この分析により、主に自動車セグメントの成長が全体の売上高に大きく寄与していることが確認できます。航空宇宙セグメントには改善の余地があります。

#-----

最後に、線形回帰結果を図 6 に以下に示す。そして、2021 年,2022 年のデータを学習データから故意的に削除した線形回帰結果を図 7 に示す。それぞれのモデルでの予測値，真値，評価値を以下の表 13 に示す。

表 13. モデルの評価結果

	予測値	真値	評価値
モデル1	119346	166435	0.72
モデル2	143049		0.86




図 6. 線形回帰結果 1




図 7. 線形回帰結果 2

## 2.5. 考察

本実験における考察を以下の3項に分けて行う。

### (1) 表形式データの抽出について

本実験では、xbrl形式ファイルから、売上や開発費などのデータに該当する部分をChatGPTを用いて抽出し、一定形式の表にまとめた。従来の手作業に比べて、非常に高速で大量のデータに対して行える点がメリットとして考えられる。一方で、億や数百万などの省略されている桁数に関しては、誤って記録される場合があるとわかった。理由としては、XBRLファイルは「100（百万円）」や「25（億円）」のように、数値と単位が分離されていることが多いためであると考えた。人間が表を視認する場合は、全ての数字に億円などについていると、無駄に感じやすい。一方で、機械が理解する場合は別々の要素と捉える場合があるため、誤認識につながったと考えた。

### (2) ChatGPTによるセグメント別評価について

本実験におけるChatGPTによるセグメント別分析は、各年の売上データに基づいて時系列の変動を正確に捉え、自然な言語で要約する能力の高さを示している。特に、自動車セグメントの売上が2021～2022年に一時減少し、2023～2024年に大きく反発している点を的確に記述しており、数値の変化とその意味付けを伴った分析がなされていた。これは、新型コロナウイルス感染症流行により、支出を最小限にした結果であると考えられる。航空宇宙セグメントについても、長期的な減少傾向と、近年の小幅な回復という2段階の流れを自然にまとめており、流れの整理力が高いと評価できる。さらに、各セグメント間の比較構造が明確で、「自動車が全体売上に大きく寄与」「その他セグメントは安定的かつ規模が小さい」といった位置づけが記述されている点も評価できる。これらより、単に数値を並べるだけでなく、ビジネス文脈に応じた重要性や影響力の差異を理解しやすくなっている。また、表現も非常に自然で、報告書やプレゼン資料への転用も可能なレベルの出力が得られている。一方で、注意点としては、XBRL由来のデータでは「千億円」や「百万円」などの単位が明示的に記載されていないことも多く、モデルが文脈解釈を誤るリスクがあることだ。今回のケースでは正しく処理されているが、今後の応用においては単位・桁数を事前に明示するなど、プロンプト設計や前処理の工夫が重要となる。よって、プロンプトエンジニアリングといった手法を利用することで、少ないトークン数、コストで良い結果を得やすくすることの重要性であると感じた。以上のことから、ChatGPTは構造化データをもとにした要約・分析において、正確性・構造化性・可読性のいずれにも優れており、人手による作業の効率化に貢献するツールとして有望であると評価できる。

### (3) 線形回帰モデルによる予測について

図 6,7 は、自動車セグメントにおける開発費の過去データに基づいて線形回帰モデルを構築し、将来の傾向を予測したものである。特に 2021 年と 2022 年のデータはコロナ禍による一時的な影響を受けており、モデル精度に悪影響を与える可能性があるため、意図的に除外されている。上段のグラフはそれらを除いたデータに基づいて回帰を行っており、比較的強い上昇傾向が導かれている。

実際、2023 年・2024 年の開発費が大きく増加していることから、モデルの傾向と整合的であり、近年の EV 開発やソフトウェア化の進展などを背景とした投資増加をうまく捉えていると考えられる。一方、下段のグラフはより多くの過去データを含んでおり、回帰線の傾きは非常に緩やかで、ほぼ横ばいに近い。これは過去の低い水準のデータによって平均化され、直近の成長トレンドを過小評価してしまっている結果といえる。

この比較から分かるように、線形回帰モデルでは、使用する期間のデータの選定が予測結果に大きく影響する。特に自動車のよう、近年で大きく投資構造が変化している産業では、過去データに引っ張られすぎると実態に合わない予測が生成される可能性がある。したがって、近年のデータに重みを置く、あるいは異常値を除外する手法は、実務上有効なアプローチと考えられる。また、モデルはあくまで線形であるため、将来にわたってもこの成長が直線的に続くとは限らない。今後、非線形回帰や要因分析を組み合わせることで、より実態に近い予測を実現できる可能性がある。今回の結果からは、自動車開発費は回復・成長傾向にあり、線形回帰を通じてその方向性をある程度把握できることが示された。

## 2.6. 結論

本実験では、自動車セグメントの開発費データに対して線形回帰モデルを適用し、将来の傾向を予測した。その結果、2021 年・2022 年のコロナ影響による異常値を除外することで、近年の成長トレンドを正しく捉えた回帰モデルが得られた。一方、過去の低い水準のデータを多く含むモデルでは成長傾向が過小評価され、実際の最新データとの乖離が見られた。これにより、線形回帰モデルの有効性は、使用する期間や外れ値の扱いに大きく依存することが明らかとなった。今後の予測精度向上のためには、線形回帰ではない形式での予測モデルの開発と適切な前処理が不可欠であると結論づけられる。

### 3. 感想

本実験を通じて、線形回帰による定量的な傾向分析だけでなく、ChatGPT のような自然言語処理（NLP）モデルの有用性についても改めて実感した。ChatGPT を用いることで、数値データの変化に対する背景の説明や要因の整理、文章による要約が自動的に行える点は非常に魅力的であり、実務や報告書作成において大きな効率化が期待できる。ただし、ChatGPT ですべて完結できるレベルには達しておらず人間が適宜確認することが重要な段階であると感じた。また、今回のように売上や開発費の変動を自然言語で読み解くタスクでは、モデルが人間のような視点でトレンドを抽出し、因果関係を仮定しながら説明を付加してくれるため、単なるグラフや表では見えにくい意味合いを可視化することができた。

一方で、ChatGPT は自然言語の柔軟な解釈が得意な反面、単位や桁数、外れ値処理などの厳密な数値処理に関しては注意が必要であるとも感じた。したがって、定量分析と自然言語処理の出力を組み合わせることで、データの「何が起きたか」と「それが何を意味するか」の両方を包括的に理解できるアプローチが可能となる。今後は、定量モデルと NLP モデルをハイブリッドに活用することで、より精度の高い分析や戦略立案が実現できると考えた。

### 4. 参考文献

- (1) IBM, NLP(自然言語処理)とは,  
(<https://www.ibm.com/jp-ja/think/topics/natural-language-processing>),  
2025/06/30 参照。
- (2) OpenAI API Platform, Docs,  
(<https://platform.openai.com/docs/overview>),  
2025/06/30 参照。